

역할 기반 데이터셋과 RAG 결합 시스템 프롬프트를 활용한 한국어 자기소개서 기반 면접 질문 생성

Korean Cover-Letter-Based Interview Question Generation with Role-Aware Datasets and RAG-Enhanced System Prompts

김영언

Young-Eon Kim

경상국립대학교

Gyeongsang National
University

young03@gnu.ac.kr

고건민

Geon-Min Ko

경상국립대학교

Gyeongsang National
University

2024080064@gnu.ac.kr

박지홍

Ji-Hong Park

경상국립대학교

Gyeongsang National
University

hong_0002@gnu.ac.kr

임소희

So-Hee Lim

경상국립대학교

Gyeongsang National
University

220161103@gnu.ac.kr

김건우*

Gun-Woo Kim

경상국립대학교

Gyeongsang National
University

gunwoo.kim@gnu.ac.kr

* 교신 저자

요약문

본 연구는 한국어 자기소개서를 기반으로 면접 질문을 생성하는 KoBART 기반 시스템을 제안하였다. 먼저 역할 정보 없이 구성된 약 1 만 개 데이터셋과, 직무·기업 인제상·지원자 페르소나를 Role Prompt로 포함한 약 3 천 개 역할 기반 데이터셋을 비교한 결과, 후자가 BLEU, METEOR, TF-IDF, SBERT 등 주요 지표에서 전반적으로 더 높은 성능을 보였고, 질문에 직무·기업 맥락이 보다 뚜렷하게 반영되었다. 또한 역할 기반 KoBART를 고정한 상태에서 Prompt-only, Random-RAG, Prompt+RAG를 비교한 실험에서 Hybrid RAG 설정이 Coverage, Goundedness, Distinct-2 모두에서 가장 우수한 결과를 나타냈다. 이를 통해 역할 정보가 포함된 데이터셋과 RAG 기반 근거 결합이 질문 생성의 정확성과 맥락 적합성을 동시에 향상시키는 효과적인 방법임을 확인하였다.

주제어

자기소개서 기반 면접 질문 생성, 역할 기반 데이터셋, 대규모 언어모델(LLM), 검색증강생성(RAG), 시스템 프롬프트 최적화

1 서론

최근 채용 과정에서는 자기소개서나 이력서를 자동으로 분석해 지원자의 역량과 직무 적합성을 평가하려는 시도가 점점 늘어나고 있다[1-3]. 특히 대규모 언어모델(Large Language Model, LLM)을 활용한

면접 질문 자동 생성 서비스가 등장했으나, 실제 기업이 선호하는 가치나 지원자의 개별 경험, 성향까지 함께 반영된 질문을 만들어내는 수준에는 아직 이르지 못하고 있다[4][5].

LLM은 높은 생성 성능에도 불구하고, 근거가 부족한 내용을 그럴듯하게 만들어 내는 환각(Hallucination) 문제가 빈번하게 지적된다[2]. 특히 채용처럼 결과가 직접적으로 의사결정에 영향을 주는 환경에서는, 경험과 무관하거나 기업 가치와 전혀 관련 없는 질문이 생성되면 신뢰도를 확보하기 어렵다. 이를 보완하기 위해, 외부 지식을 검색해 모델 입력에 함께 제공하는 검색 증강 생성(Retrieval-Augmented Generation, RAG)[1]과, 역할·제약·검증 단계를 나누어 지시하는 구조화 시스템 프롬프트(Structured System Prompt)(예: STEP)[3]가 다양한 도메인에서 성능 향상과 신뢰성 개선에 효과적임이 보고되고 있다.

한국어 환경에서 KoBART는 한국어 말뭉치를 기반으로 학습된 BART 계열 모델로서 요약·질문 생성 등에서 안정적인 성능과 재현성을 보여, 한국어 자기소개서 텍스트를 다루는 생성 모델의 기본 생성기로 적합하다[6]. 본 연구는 이러한 장점을 고려하여 KoBART를 채택하였다.

그러나 자기소개서 기반 면접 질문 생성 분야에는 여전히 연구적 공백이 존재한다. 첫째, 직무, 기업 인제상, 지원자 페르소나 정보를 명시적으로 포함한 한국어 역할 기반 데이터셋이 거의 구축되어 있지 않다. 둘째, 다양한 프롬프트 기법(Chain-of-Thought,

Few-Shot, Retrieval, Self-Ask, Role Prompt 등)을 동일 태스크 내에서 비교한 연구가 부족하다. 마지막으로, RAG와 System Prompt를 결합했을 때 생성된 질문의 커버리지(Coverage), 근거성(Groundedness), 다양성(Distinct-2)이 실제로 얼마나 개선되는지에 대한 정량 평가(Quantitative Evaluation) 사례가 거의 보고되지 않았다.

본 논문은 위의 한계를 극복하고, 자기소개서 기반 면접 질문 생성의 신뢰성과 맥락 적합성(Contextual Relevance)을 동시에 확보하는 효과적인 파이프라인(Pipeline)을 제안하는 것을 목적으로 한다. 크게는 두 가지 주요 기여를 한다. 먼저, Role Prompt 구조를 활용하여 직무, 기업 인재상, 지원자 페르소나가 반영된 역할 기반 데이터셋 약 3,000 개를 구축하고, KoBART를 파인튜닝(Fine-tuning)하여 면접 질문 생성 모델을 학습시킨다. 나아가, 학습된 KoBART 모델 위에 RAG와 System Prompt를 결합하여, Prompt-only 방식 대비 질문의 커버리지, 근거성, 다양성 측면에서 성능 향상을 정량적으로 검증한다.

2 본문

2.1 문제 정의

본 연구는 자기소개서 기반 면접 질문 생성을 핵심 태스크로 다룬다. 구체적으로는 한국어 자기소개서에 포함된 특정 경험 서술을 입력으로 받아, 해당 경험과 지원자의 직무, 기업 인재상, 페르소나 정보를 조건으로 고려하여 면접 질문 리스트를 생성하는 과제이다. 입력은 자기소개서의 경험 서술 문단(input) 외에도, 지원 직무(job type), 지원 기업명(company)과 그 기업이 제시한 핵심 가치를 담은 기업 인재상(company_value), 그리고 지원자의 성향·강점·핵심 역량 등을 요약한 지원자 페르소나(persona) 정보로 구성된다. 출력(output)은 이러한 역할 정보(role information)를 조건으로 생성된 면접 질문들로 구성되어 있으며, 각 질문은 경험의 핵심을 확인하거나 기업이 중요하게 여기는 가치와의 적합성을 점검하는 방향으로 생성되는 것을 목표로 한다.

따라서 본 연구가 다루는 문제는 단순 요약이나 키워드 추출과는 성격이 다르다. 동일한 경험이라도 직무, 기업 인재상, 지원자 특성의 조합에 따라 질문의 초점이 달라져야 하기 때문이다. 이때, 입력과 출력 간의 문장 구조가 다르고, 동일한 어휘가 겹치는 일도 거의 없기 때문에, 번역·요약 과제에서 널리 사용하는 BLEU, ROUGE-L과 같은 단어 중복 기반 지표는 모델 성능을 충분히 반영하기 어렵다. 이에 따라 본 연구에서는 이러한 조건부 생성 문제를 역할 정보가 반영된 질문 생성으로 정의하고, 정량적 평가는 후속 절에서 다룬다.

2.2 데이터셋 구축

데이터셋 구축을 위해 먼저 실물 한국어 자기소개서 100 편을 수집하였다. 문서들은 다양한 직무와 기업을 포함하며, 성장 과정, 지원 동기, 직무 역량, 입사 후 포부 등 여러 문단으로 구성되어 있다. 수집한 문서에서 개인 식별 가능 정보는 모두 제거한 뒤 연구용으로만 활용하였다.

연구 초기에는 이 100 편의 자기소개서를 기반으로 생성형 언어모델(Generative Language Model)을 활용하여 약 10,000 개의 (입력, 출력, 가중치) 데이터셋을 구축하였다. 이때 입력은 경험 서술문, 출력은 해당 경험을 기반으로 한 면접 질문 3~8 개, 가중치는 출력 질문 개수에 따라 부여한 값으로만 구성되었다. 즉, 직무 정보, 기업 인재상, 지원자 페르소나와 같은 역할 정보는 데이터에 포함되어 있지 않았다. 해당 데이터셋으로 모델을 학습한 결과, 손실 감소는 확인되었으나 질문이 기업 인재상이나 지원자 유형에 맞게 조정되지 않는 한계가 나타났다. 본 연구에서는 이 데이터셋을 역할 정보가 없는 Baseline으로 간단히 소개하고, 주요 실험과 분석은 역할 정보가 포함된 새로운 데이터셋을 중심으로 진행한다.

역할 정보를 명시적으로 포함하기 위해, 본 연구는 실물 한국어 자기소개서 100 편을 기반으로 약 3,000 개의 역할 기반 데이터셋을 구축하였다. 수집 단계에서 각 자기소개서는 지원 기업과 직무가 이미 명시된 상태로 정리되었으며, 이후 문서를 3~4 개 문단 단위로 청킹(Chunking)한 뒤 실제 면접 질문의 근거가 될 수 있는 핵심 경험 문단을 선별하였다. 이렇게 추출된 경험 서술문은 원 자기소개서의 직무·기업 맥락을 유지한 채 활용되었고, 각 경험 문단에 대해 지원 직무, 지원 기업명, 기업 인재상(company_value), 그리고 지원자의 성격·강점·핵심 역량을 요약한 페르소나(persona)를 부여하였다. 이때 직무와 기업 정보는 원문에 기반해 고정되며 임의로 생성되거나 혼합되지 않도록 구성하였고, 페르소나와 기업 인재상은 실물 자기소개서 및 해당 기업의 공개 정보를 바탕으로 생성형 언어모델을 통해 초안을 만든 뒤 사람이 검토·수정하는 방식으로 정제하였다. 결과적으로 각 샘플은 “경험 텍스트 + 직무 + 기업 인재상 + 지원자 페르소나”로 구성되는 역할 메타데이터 구조를 갖게 되었으며, 직무·기업 인재상·지원자 특성이 경험 내용과 논리적으로 연결되도록 기준을 설정하여 역할 정보가 질문 생성의 조건으로 일관되게 작동하도록 설계하였다.

표 1. 역할기반 데이터셋의 필드 구성

항목	설명
job_type	직위 직무명
company	기업명
persona	지원자 성향·역량·가치관

company_value	기업 핵심가치 및 인재상
input	경험 서술문
output	Role Prompt 기반 질문 리스트
method	생성 방식

이 역할 정보를 활용하기 위해 면접관의 시점을 명시적으로 부여하는 Role Prompt 를 설계하였다. 프롬프트는 “당신은 한국어 면접관이다”와 같이 역할을 정의하고, 입력으로 경험 문단과 직무, 페르소나, 기업 인재상을 함께 제공하여 실제 기업 면접에서 묻는 행동 기반 질문을 생성하도록 지시하는 형태로 구성하였다.

Role Prompt 의 타당성을 확인하기 위해 Chain-of-Thought, Few-shot, Retrieval, Self-Ask, Role Prompt 등 5 가지 기법을 480 개 샘플에 적용하여 비교하였다[7]. BLEU, ROUGE-L, METEOR, BERTScore 를 계산한 결과, 단어 중복 기반 지표는 태스크 특성상 모델 간 차이를 잘 구분하지 못했으나, METEOR 와 BERTScore 와 같은 의미 기반 지표에서는 Role Prompt 가 가장 일관되게 높은 값을 보임을 확인하였다. 이에 따라 최종 약 3,000 개 데이터셋을 모두 Role Prompt 방식으로 생성하여 사용하였다.




그림 1. 다섯 가지 생성 기법의 METEOR 및 BERTScore 비교

최종 데이터는 JSON 형식으로 정리되며, 직무명, 기업명, 페르소나, 기업 인재상, 경험 서술문, Role Prompt 방식으로 생성된 질문 목록, 생성 기법(method)으로 구성된다. 이후 학습 단계에서는 이러한 역할 정보와 경험 서술을 하나의 입력 문장으로 자연스럽게 연결하여 모델에 제공하였고, 이를 통해 모델이 단순 경험뿐 아니라 기업 인재상과 지원자 특성까지 함께 고려하여 질문을 생성하도록 하였다.

2.3 모델 및 학습 설정

기본 생성기로 한국어 자기소개서 기반 면접 질문 생성을 위해 사전학습된 KoBART 모델을 사용하였다. KoBART 는 한국어 대규모 코퍼스인 재학습된 BART 계열 모델로, 조건부 생성 과제에서 안정적인 성능과 재현성을 보이며 공개 가중치를 제공해 후속 연구의 반복 실험이 용이하다.

학습 입력은 2.2 절에서 구축한 역할 기반 데이터셋을 활용하여, 경험 서술문과 함께 지원 직무, 기업 인재상, 페르소나 정보를 하나로 묶어 모델에 제공하였다. 출력은 동일한 역할 정보를 바탕으로 Role Prompt 방식으로 생성된 면접 질문 리스트이며, 모델이 이 질문을 조건부로 생성하도록 학습을 진행하였다. 전체 3,003 개 중 90%를 학습용, 10%를 검증용으로 사용하였으며, AdamW 옵티마이저(학습률 5×10^{-5}), 배치 크기 2, epoch 5 설정으로 파인튜닝을 수행하였다. 최종적으로 검증 손실이 최소가 되는 시점을 최종 모델로 저장하였다.

모델 출력의 품질 평가에는 전통적 정렬 기반 지표(BLEU, ROUGE-L)와 의미 기반 지표(METEOR, TF-IDF, SBERT)를 함께 사용하였다. RAG + System Prompt 실험에서는 입력 경험과 근거 텍스트 활용도를 측정하기 위해 Coverage, Groundedness, Distinct-2 지표를 사용하였다. 지표별 비교 및 분석 결과는 2.4 절에서 상세히 다룬다.

2.4 실험 및 결과

본 절에서는 역할 정보가 없는 기존 데이터셋으로 학습한 KoBART 모델과 역할 기반 데이터셋으로 학습한 KoBART 모델을 비교하고, 이후 동일한 모델 위에 RAG 와 구조화된 System Prompt 를 적용했을 때 질문 생성 품질이 어떻게 변화하는지를 분석하였다.

기존 Baseline 모델은 약 100 편의 자기소개서를 기반으로 확장한 약 1 만 개의 샘플로 학습되었으며, 입력 경험 서술문과 출력 질문(3~8 개)만을 포함하고 있어 직무·기업 인재상·페르소나와 같은 역할 정보가 포함되지 않은 구조였다. 이러한 제한으로 인해 학습 과정에서 검증 손실은 약 1.29~1.35 수준으로 수렴하며 수치상 일정 수준의 성능을 보였지만, 실제 생성된 질문은 서로 유사한 패턴을 반복하거나, 기업 인재상과 무관한 일반적 질문을 출력하는 경향이 강했다. 직무가 달라져도 질문 초점이 크게 변하지 않는 등 의미적 한계도 확인되었다. 이는 데이터셋에 역할 정보가 없고, 출력 질문 개수만으로 가중치를 조정했기 때문에 모델이 새로운 상황에 맞춘 질문을 생성하기보다는 빈번하게 등장하던 질문 패턴을 반복하는 방향으로 수렴하였음을 의미한다.

반면, 약 3,000 개 규모의 역할 기반 데이터셋을 학습한 모델은 각 샘플에 직무, 기업 인재상, 페르소나가 명시적으로 포함되어 있으며, Role Prompt 를 통해 “면접관 역할”이 부여된 상태에서 질문을 생성한 것이 특징이다. 동일한 KoBART 구조·학습률·배치 크기를 사용하여 5 epoch 동안 학습한 결과, 학습 손실은 1.97 에서 0.55 까지 안정적으로 감소하였고, 검증 손실은 약 1.52 근처에서 안정적으로 유지되었다. BLEU 는 기존 모델이 0.04~0.05 에 그쳤던 것에 비해 약 0.09~0.11 수준으로 기존 모델 대비 두 배 가까이 증가하였고, METEOR 도 약 0.25 에서 0.31 수준으로 완만히 향상되었다. 또한, 참조 질문과 생성

질문 간 TF-IDF(Term Frequency-Inverse Document Frequency) 코사인 유사도는 약 0.23 에서 0.29 까지 증가하였으며, SBERT(Sentence-BERT) 기반 의미 유사도는 약 0.84 에서 0.87 수준 까지 개선되는 경향을 보였다.




그림 2. 역할 기반 KoBART 모델의 Train-Validation Loss 변화




그림 3. 역할 기반 KoBART 모델의 에포크별 METEOR 점수 변화

정성적 분석에서도 역할 기반 모델이 직무와 기업 인재상에 따라 질문을 생성하는 경향이 뚜렷하게 나타났다. 예를 들어 동일한 “장애 대응 경험”에 대해, 기존 모델은 주로 “어떤 어려움이 있었나요?”, “이 경험에서 무엇을 배웠나요?”와 같은 일반적인 질문을 반복했지만, 역할 기반 모델은 “외부 장애 요인을 어떻게 식별했는지”, “캐시 구조 설계에서 병목 구간을 어떤 기준으로 분리했는지”, “해당 장애 대응 경험을 향후 추천 시스템 개발 업무에 어떻게 연결할 수 있는지”와 같이 질문의 초점(분석력·문제 해결·확장성 등)이 달라졌고, 직무 맥락과 기업 인재상에서 강조하는 역량을 반영한 질문을 다양하게 생성하였다. 데이터 양은 절반 이하로 줄었음에도, 오히려 과적합은 줄어들었으며, SBERT 유사도가 과도하게 1.0에 가까워지지 않고 안정적으로 증가하는 등 패턴 다양성도 더 잘 유지되었다. 이러한 결과는 단순히 데이터 양을 늘리는 방식보다, 기업 인재상과 지원자 특성을

함께 반영하는 역할 기반 데이터 구조가 면접 질문 생성에 더 직접적인 영향을 준다는 점을 보여준다.

2.5 RAG + System Prompt 실험 결과

역할 기반 데이터셋으로 학습한 KoBART는 직무·기업 인재상·경험을 반영한 질문을 생성할 수 있지만, 자기소개서 한 편이 담는 정보는 매우 넓고, 기업별 핵심 가치나 직무 도메인도 지속적으로 변화한다는 점에서 모델 파라미터만으로 모든 맥락을 처리하기에는 한계가 있다. 이러한 한계를 보완하기 위해 KoBART 위에 검색 기반의 RAG 구조와 구조화된 System Prompt를 결합하여 외부 근거 문장을 함께 제공했을 때 질문 생성 품질이 어떻게 달라지는지 추가 실험을 진행하였다.

실험에서는 전체 3,003 개 데이터 중 10%인 301 개를 테스트셋으로 사용하였고, 이 중 최대 50 개 샘플에 대해 다음 세 가지 조건을 비교하였다.

- **Random-RAG(B0):** 학습 데이터에서 무작위로 선택한 문장을 근거(evidence)처럼 프롬프트에 넣고 질문을 생성한 경우
- **Prompt-only(B1):** 역할 정보만 활용하고 검색 없이 KoBART가 직접 생성한 경우
- **Prompt+ RAG(B2):** BM25와 SBERT 임베딩을 결합한 hybrid retriever로 검색한 근거 문장을 system prompt에 (E1)...(E5) 형태로 삽입하여 질문을 생성한 경우

질문 품질 평가는 정답 문장과 유사도보다는, 모델이 실제 텍스트를 얼마나 활용하는지를 확인하는 데 중점을 두었다. 이를 위해 세 기준을 사용하였다. 첫째, Coverage는 자기소개서에서 추출한 핵심 키워드가 질문에 얼마나 포함되는지를 나타내며, 모델이 입력의 여러 측면을 고르게 다루는지 판단하는 지표이다. 둘째, Groundedness는 생성된 질문이 근거 텍스트(검색 문장 및 원문)와 일정 수준 이상의 TF-IDF 유사도를 갖는 비율로, 질문이 실제 텍스트에 기반해 생성되었는지를 평가한다. 셋째, Distinct-2는 두 단어가 이어진 표현(2-gram)이 얼마나 다양하게 등장하는지를 계산하여, 질문 내 표현이 반복되지 않고 충분한 다양성을 갖추었는지를 평가한다.

실험 결과, Random-RAG(B0)는 Coverage 0.25, Groundedness 0.11, Distinct-2 0.34 수준으로 나타나, 무작위 문장을 근거로 제공하는 방식은 오히려 질문 품질에 부정적 영향을 미치는 것으로 확인되었다. Prompt-only(B1)는 Coverage 0.49, Distinct-2는 0.58로 Random-RAG보다 분명히 우수했으나, Groundedness는 0.05 수준으로 매우 낮게 나타났다. 이는 역할 기반 KoBART가 경험·페르소나·인재상을 바탕으로 “그럴듯한 질문”을 다양하게 생성할 수는 있지만, 근거 문장의 세부 표현을 직접 참조하

기보다는 내부 파라미터에 저장된 일반 패턴에 의존하는 경향이 강하다는 점을 보여준다.

반면, Prompt+ RAG(B2)조건에서는 세 지표가 모두 개선되었다. Coverage 는 0.67로 Prompt-only 대비 약 0.18p 증가하여, 생성된 질문들이 자기소개서의 다양한 키워드를 더 폭넓게 다루는 것으로 나타났다. Groundedness 역시 0.29 까지 상승하여, 질문이 입력 텍스트와 검색된 근거 문장의 핵심 표현을 더 직접적으로 반영하는 경향을 보였다. Distinct-2 도 0.78 수준으로 상승하여, 질문의 표현·관점이 더 다양해졌다. 이는 RAG 가 단순한 검색 기능을 넘어서, 자기소개서의 다양한 측면을 균형 있게 반영하고, 실제 근거에 기반한 질문을 생성하도록 유도하는 데 효과적임을 시사한다.




그림 4. RAG + system prompt 적용 여부에 따른 Coverage·Groundedness·Distinct-2 비교 결과

정성적 분석에서도 동일한 경향이 나타났다. 예를 들어, “소셜 미디어 광고 성과 분석” 경험을 입력으로 제공했을 때 Prompt-only 는 “학습 효과에 어떤 영향을 주었는지”와 같은 일반적 질문을 생성한 반면, Prompt+ RAG 는 검색된 근거 문장에서 등장한 “A/B 테스트”, “성과 데이터(노출, 클릭, 전환)” 등의 용어를 직접 반영하여 광고 효율성, 의사결정 기준, 실험 설계 방식 등을 구체적으로 묻는 질문을 생성하였다. 또한 “CI/CD 파이프라인” 관련 경험에서도 Prompt+ RAG 는 검색된 도메인 문장을 활용하여 CI/CD 의 개념과 중요성, 자동화된 테스트와 배포 프로세스의 의미를 직접적으로 언급하는 질문을 생성하는 등, 도메인 지식을 동반한 질문이 더 많이 나타났다.

질문 문장 자체는 아직 매끄럽지 않은 부분이 있지만, 전반적으로 역할 기반 KoBART 에 RAG 와 구조화된 System Prompt 를 결합한 구성은 Coverage, Groundedness, Distinct-2 세 측면에서 모두 향상된 결과를 보여주었다. 이는 면접 질문 생성에서 단순 프롬프트 기반 생성보다 외부 근거 결합 방식이 더 효과적임을 정량·정성적으로 입증하였다.

2.6 한계점 및 향후 연구 방향

본 연구에서 구축한 역할 기반 데이터셋은 약 3,000 개 규모로, 직무·기업 인재상·지원자 페르소나를 함께 포함한다는 점에서 기존 데이터셋보다 구조적으

로 개선된 형태이지만, 다양한 산업과 직무군을 충분히 반영하기에는 아직 범위가 제한적이다. 또한 역할 기반 데이터셋 구축 과정에서 일부 메타데이터, 특히 지원자 페르소나와 기업 인재상은 생성형 언어모델을 활용해 초안을 생성한 뒤 사람이 검토·수정하는 방식으로 구성되었기 때문에, 일부 샘플에서는 표현의 일관성이나 실제 정보와의 정합성이 완벽하지 않을 가능성도 존재한다. 직무와 기업 정보 자체는 실물 자기소개서에 기반해 고정된 상태로 활용되었으나, 메타데이터 서술 방식에 따라 특정 직무나 집단의 특성이 상대적으로 강조될 가능성에 대한 논의는 향후 보다 체계적으로 보완될 필요가 있다. 더불어 데이터 정제 과정에서 사람의 개입이 요구되었고, RAG 기반 검색 역시 코퍼스의 범위와 품질에 따라 성능이 크게 좌우되기 때문에, 특정 전문 분야에서는 근거 문장을 충분히 확보하지 못하는 한계가 존재한다. 이러한 점을 고려할 때, 역할 기반 데이터셋의 타당성과 투명성을 강화하기 위해 메타데이터 생성 기준의 명시화, 편향 점검 절차의 정교화, 그리고 차별 방지 및 윤리적 고려 사항을 보다 구체적으로 다루는 후속 연구가 필요하다.

한편 본 연구의 평가는 주로 자동 지표 기반으로 이루어져 있어, 생성된 질문이 실제 면접 상황에서 얼마나 적절하게 기능하는지에 대한 인간 중심의 정성적 평가는 충분히 포함하지 못했다. 채용은 질문의 표현 방식이나 초점에 따라 지원자의 부담감, 수용성, 응답 전략에 영향을 미칠 수 있는 민감한 영역이므로, 면접관 또는 현업 HR 전문가를 포함한 평가를 통해 질문의 타당성·공정성·실무 활용 가능성을 검증하는 과정이 중요하다. 또한 실제 사용자를 대상으로 한 인터페이스 경험 측면의 평가가 함께 이루어진다면, 질문 생성 시스템이 면접 지원 도구로서 어떤 방식으로 인식되고 활용되는지에 대한 분석이 가능해져 HCI 관점에서의 기여도 역시 더욱 명확해질 것이다.

그럼에도 본 연구는 자기소개서 기반 질문 생성에서 역할 정보(직무·인재상·페르소나)를 구조화해 모델에 제공하는 방식이 모델이 질문의 관점을 잡는 데 결정적 영향을 미친다는 점을 실험적으로 확인하였다. 즉, 질문 패턴이 단순 반복되는 기존 데이터셋과 달리, 지원자·기업 맥락을 명시적으로 포함한 데이터 설계가 모델 품질을 좌우하는 핵심 요소임을 보여주었다. 최종적으로, KoBART 에 RAG 와 System Prompt 를 결합하면, 질문이 실제 텍스트와 더 잘 연결되고 다양한 관점을 포함하도록 유도할 수 있어, 향후 HR 면접 지원 도구로 확장될 가능성을 확인할 수 있었다.

향후 연구에서는 더 다양한 직무와 기업 사례를 포함한 역할 기반 데이터셋을 확장하고, 각 산업 분야의 실제 문서를 활용해 RAG 용 참고 자료를 더 풍부하게 만드는 작업이 필요하다. 더 나아가 페르소나·인재상 자동 생성 및 데이터 정제 자동화 기법을 도입함으로써 전체 파이프라인의 효율성과 재현성을 높이는 방향으로 연구가 확장될 수 있다.

3 결론

본 연구는 서론에서 제기한 세 가지 핵심 문제 —자기소개서·기업 인재상·지원자 특성이 함께 반영된 데이터셋의 부재, 프롬프트 기법 간 체계적 비교의 부족, 그리고 외부 지식 결합 방식(RAG)의 실제 효과에 대한 불확실성—에 대해 실험적으로 접근해 그 결과를 정리하였다. 초기 실험에서 경험 문단만을 입력으로 사용하는 방식은 질문의 관점이 일정한 패턴으로 수렴하며, 직무나 기업 가치와의 연관성을 확보하기 어렵다는 한계가 명확히 확인되었다.

이후 구축한 역할 기반 데이터셋은 직무·기업 인재상·지원자 페르소나를 함께 입력으로 제공하는 구조를 가지고 있으며, 동일한 KoBART 모델을 사용하더라도 질문의 초점이나 표현 방식이 역할 정보에 따라 달라지는 결과를 보였다. 특히 질문이 어떤 역할을 중심으로 파고드는지, 경험의 어느 부분을 근거로 삼는지 등이 보다 명확하게 분리되며, 단순 경험-only 데이터셋에서 나타나던 질문 패턴 반복 문제도 상당 부분 감소하였다. 이는 질문 생성 과정에서 텍스트 양보다 입력 구조와 조건 설계가 더 큰 영향을 미칠 수 있음을 시사한다.

또한 RAG와 System Prompt를 결합한 실험에서는, 모델이 검색된 근거 문장을 실제로 활용하면서 Coverage·Groundedness·Distinct-2 모두에서 긍정적인 변화가 나타났다. 특히 질문이 도메인 용어나 개념을 보다 직접적으로 반영하는 경향이 증가해, 단순히 “더 자연스럽다”는 수준이 아니라 모델이 참조할 수 있는 구체적 근거를 확보했을 때 생성 방향이 어떻게 달라지는지를 확인할 수 있었다.

종합하면, 본 연구는 한국어 면접 질문 생성에서 “무엇을 얼마나 많이 학습시키는가”보다 “어떤 형태로 정보를 제공하느냐”가 더 결정적일 수 있음을 보여준다. 역할 정보를 구조화와 근거 기반 생성 방식을 도입하는 것이 질문의 품질과 신뢰성을 끌어올리는 핵심 요소로 작용했다는 점은, 앞으로의 HR·채용 관련 LLM 연구가 어떤 방향으로 설계되어야 하는지에 대한 실질적인 기준을 제공한다. 본 연구에서 제시한 접근 방식은 향후 자기소개서 자동 분석, 면접 지원 시스템, AI 기반 코칭 도구 개발 등 다양한 실무 응용으로 확장될 가능성을 가지고 있다.

사사의 글

본 논문은 교육부와 경상남도의 재원으로 지원을 받아 수행된 경상남도 지역혁신중심 대학지원체계(RISE) 연구결과 및 2025년도 산업통상자원부 및 한국산업기술기획평가원(KEIT)의 연구비 지원(RS-2025-02633048)에 의한 연구결과입니다.

참고 문헌

1. Guo, K. X., Wong, P. K.-Y., Cheng, J. C. P., Chan, C.-F., Leung, P.-H. and Tao, X.

Enhancing visual-LLM for construction site safety compliance via prompt engineering and bi-stage retrieval-augmented generation. *Automation in Construction*. 179. Elsevier. pp. 106490. 2025.

2. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A. and Fung, P. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*. Association for Computing Machinery (ACM). pp. 1-42. 2023.
3. Ma, F., Li, D., Liu, Y., Lan, D., and Pang, Z. STEP: A structured prompt optimization method for SCADA system tag generation using LLMs. *Journal of Industrial Information Integration*. 45. Elsevier. pp. 100832. 2025.
4. Kim, E., Suk, J., Kim, S., Muennighoff, N., Kim, D. and Oh, A. LLM-as-an-Interviewer: Beyond Static Testing Through Dynamic LLM Evaluation. <https://arxiv.org/abs/2412.10424> June 1, 2025.
5. Nguyen, T. T. H., Nguyen, T. D. Q., Cao, H. L., Tran, T. C. T., Truong, T. C. M. and Cao, H. SimInterview: Transforming Business Education through Large Language Model-Based Simulated Multilingual Interview Training System. <https://arxiv.org/abs/2508.11873> August 16, 2025.
6. 전재성, 이수안. 한국어 논문 요약을 위한 KoBART와 KoBERT 모델 비교. *한국정보과학회 언어공학연구회 학술대회논문집*. 한국정보과학회. pp.562-564. 2022.
7. Topal, M. B., Bozanta, A. and Başar, A. How do LLMs perform on Turkish? A multi-faceted multi-prompt evaluation. *Expert Systems with Applications*. 279. Elsevier. 2025.